洛谷接入：可行性与必要性分析

> 面向 PKU《计算概论 B》离线学习终端（`D:\opencode\course-terminal`） 2026-10-03 | 技术结论全部来自本机一手实测（只读、低频、不登录、不提交）

结论速览

维度	判断	一句话
技术	✅ **完全可行，成本比预期低一个量级**	洛谷**官方提供整库离线导出**（26.8 MB，17,546 道题，含完整题面），**匿名可下**，不用爬 HTML
合规	⚠️ **看用哪条路**	官方离线库 = 官方渠道；实时抓取 = 踩协议 §3.4.10；**再分发** = 踩 §4.1
必要	🟡 **有真实缺口，但"接洛谷"不是唯一解**	真缺口是「学完一个知识点没有题可练」；洛谷是**最现成**的补法，不是唯一解
建议	**做，但做"离线精选"，不做"实时在线"**	见 §6

一、洛谷是什么

项	事实
上线	2013-06-15，上海洛谷网络科技有限公司运营（2018 成立）
规模	截至 2025 年底：**200 万+ 用户 / 15,000+ 公有题 / 2.5 亿次评测**（官方口径，无公开 DAU）
自我定位	面向**小学、初中、高中**的信息学竞赛选手
难度	**8 档**：入门(红) 普及−(橙) 普及(黄) 普及+提高−(绿) 提高(青) 提高+省选−(蓝) 省选NOI−(紫) NOI+(黑)
语言	20 种；**Python 3.13.5（含 NumPy 2.3.1）+ PyPy3**
题库结构	公有题 + 团队私有题 + RemoteJudge（Codeforces 等）
官方题单	连号 **100–117**，其中 100 顺序结构 / 101 分支 / 102 循环 / 103 数组 / 104 字符串 / 105 函数与结构体

和课程现有 OJ 的关系

课程用的是 `xzmdsa.openjudge.cn`（计概&数算B-谢正茂班，管理员含 `GMyhf`=闫宏飞）。

	OpenJudge（课程）	洛谷
定位	**课程配套**，老师出题、按昵称统计成绩	**竞赛题库**，海量、梯度化、有社区
当前题量	2 份作业 × 6 题 = **12 题** + 讲义例题个位数	**17,546 道**，其中入门+普及− = **3,173 道**
登录	不需要	题面不需要；题解/记录/团队需 401

> **不是替代关系，是互补关系**：OpenJudge 解决"交作业"，洛谷解决"练手"。

二、必要性：缺口在哪

2.1 真实缺口："学完 → 练手"这条链是断的

课程现在的形态：

```
讲义（有内容） → 作业（12 题，整份交） → 考试
                      ↑
                没有"随学随练"的入口
```

一个学生在"第 3 节：for 循环"学完，想立刻练 5 道同类题——**现在做不到。**

2.2 一个被自己人忽略的证据：课程讲义里已经在引用洛谷

`content/notes/ch03.md:1022`，例题「A+B Problem」：

```
> 来源：[洛谷 P1001](https://www.luogu.com.cn/problem/P1001)
```

（同一内容在 `content/ch03.json:782` 和 `app/dist/content/` 的副本里。）

但学生点不动它 —— 离线壳里这是个死链。讲义作者已经认为洛谷是合理来源了，工具没接住。

2.3 定量对比

来源	可练题数
课程作业	12
讲义例题（OpenJudge）	个位数
洛谷 难度1+2	**3,173**

按标签：模拟 1,316 ｜ 数学 1,907 ｜ 枚举 909 ｜ 图论 618 ｜ 排序 575 ｜ 字符串 573 ｜ 递推 287 ｜ 递归 173。**每个知识点都能配出几十道同类题。**

2.4 但有先例表明这条路是通的（也表明它的边界）

正面先例（3 个可核实的具名案例）：

学校 / 课程	用法	原文证据
北京师范大学《Python编程与数据分析》（胡韧奋）	洛谷团队作业 = 正式课后练习，占成绩 30%	「**我们本学期布置的课后练习均以洛谷团队中的作业形式发放**」`bnupython.com`
沈阳化工大学《程序设计竞赛》	洛谷排名直接作实验成绩	「排名结果就可以作为实验的成绩」`syuct.edu.cn/info/1017/2916.htm`
华南师范大学《高级语言程序设计》	洛谷团队作业 + 官方入门题单 100–105	「程序设计基础实验：在洛谷注册…」`scholat.com/course/cplus`

北师大这条最有参考价值——因为它是**Python 课**，且踩过同样的坑：

> 「洛谷用户主力语言为 C++……**洛谷中大部分难题是只有 C++ 才能通关的**」 → 该课程的应对是：**只用「入门」和「普及−」难度**，并声明练习题"一定都是经过测试，可以用 Python 在限定时间、空间内完成的"。

对项目的直接启示：选题必须卡在难度 1–2，这不是审美偏好，是 Python 的硬约束。

2.5 没有证据的部分（必须说清）

- **北大计算概论与洛谷：零证据。** 没找到任何北大计概（A/B/C 班、任何年份）推荐或提及洛谷的公开材料；所有可检出的北大计概作业与上机都在 OpenJudge 上。`csintro2026.zhengmao.ltd` 实测只是一个写着「hello! dsa2026」的占位页。
- 所以**不能**论证"北大学生需要洛谷"。能论证的只有：**课程题目供给量太小，而洛谷能补上，且已有 3 所高校这么做过。**

三、技术可行性：一手实测

3.1 三条路，都已实测

路线 ①：官方离线整库 —— ✅ 决定性发现

洛谷开放平台「评测能力」页公布了一个离线题库下载地址。实测：

```
HEAD https://cdn.luogu.com.cn/problemset-open/latest.ndjson.gz
  -> 200    Content-Length = 28,113,001 (26.8 MB)
            Last-Modified = Fri, 02 Oct 2026 21:21:44 GMT
            Server = Tengine
Range: bytes=0-65535  -> 206    （支持断点续传）
```

无鉴权、匿名直接 200。 拉全并解析：

```
总共 17,546 道题
难度分布 {0:335, 1:1172, 2:2001, 3:2387, 4:2614, 5:2897, 6:637, 7:3588, 8:1915}

每行一道题的字段（14 个）：
pid, type, difficulty, samples, limits, tags, title,
background, description, inputFormat, outputFormat, hint, locale, translations
```

P1001 实例：

```
pid         = "P1001"
title       = "A+B Problem"
difficulty = 1
tags        = ["模拟"]
samples     = [["20 30\n", "50\n"]]
limits      = {"time": [...], "memory": [...]}
description = "输入两个整数 $a,b$，输出它们的和。…"   (208 字符)
inputFormat = "输入两个以空格分隔的整数 $a,b$。"
outputFormat= "输出一个整数，表示 $a+b$。"
hint         = "**数据范围**\n\n对于所有测试数据，$-10^9 \le a,b \le 10^9$…" (3,282 字符)
translations= {"en": …, "zh-CN": …}
```

> **这条路的含义**：不用爬 HTML、不用过 cookie 挑战、不用管改版、一次 26.8 MB CDN 下载就是**全库**。 格式 NDJSON（一行一题）+ gzip，**纯标准库 `gzip` + `json` 就能读**，和项目现有 `_fetch-oj.py` 的技术栈完全一致。

路线 ②：网页抓取（题面页）—— ✅ 可行，但没必要了

实测（浏览器同款请求头 + CookieJar）：

接口	状态	拿到了什么
`/problem/P1001`	**200** / 43,363 B	完整题面（结构化 JSON）
`/problem/list?page=1`	**200** / 64,261 B	`count=17628`，可分页
`/problem/list?difficulty=N` / `?tag=N`	**200**	按难度/标签筛选
`/training/100`（官方题单）	**200** / 15,159 B	题单内容
`/problem/solution/P1001`（题解）	**401**	❌ 需登录
`/record/list`（评测记录）	**401**	❌ 需登录
`/training/9378`（用户题单）	**401**	❌ 需登录

数据在 `<script id="lentille-context" type="application/json">` 里，`data.problem` 共 18 字段。

> ⚠️ **两个过时的"常识"（实测证伪）**：
>
> 1. 网传的 `_feInjection` 变量名**已失效**（出现 0 次）；
> 2. `?_contentOnly=1` 和 `x-luogu-type: content-only` **现在都返回 HTML 而非 JSON。**
> 3. 裸请求会撞 302 + `Ws-Action: cc` 挑战（`Set-Cookie: C3VK=…; Max-Age=300`），**带 CookieJar 即过。**

路线 ③：官方开放平台 API —— ✅ 正道，但进不去

- Base URL `https://open-v1.lgapi.cn`（需 OpenApp 鉴权），WebSocket `wss://open-ws.lgapi.cn/ws`
- 自述"无缝接入 **10,000+** 道精选题目"，"日均处理 200,000+ 评测"
- 已接入：**Hydro**（可导入全部题目、接收子评测详情）、UOJ、SYZOJ
- **现状：「目前正在限量邀请测试中」；官方 SDK：「暂无」**；商务邮箱 `k@luogu.org`

3.2 与现有代码的契合度：改动很小

现有 `content/homework/_fetch-oj.py`（810 行，纯标准库）已经把"抓 OJ 题面 → 结构化 JSON"做完了：

现有能力	复用到洛谷
`SECTION_ORDER = ["描述","输入","输出","提示","来源"]`	↔ 洛谷 `description/inputFormat/outputFormat/hint` **一一对应**
`RETRIES` / UA / 样例规范化（`\r\n` → `\n`、结尾补 `\n`）	直接复用
`fetched_at` 沿用旧值 → 字节级可 diff	直接复用
`AUTHORED` 表（人工解析与抓取题面分离）	直接复用——**洛谷的解析也应由人手写，不能 AI 生成**（见 §4.3）

接洛谷 ≈ 给这个文件加一个 `LuoguSource` 分支，而不是新建一套体系。

四、合规性：先把红线画清楚

4.1 用户协议（`help.luogu.com.cn/ula/luogu`）

条款	要点	对本项目
§3.4.9	不得使用未经授权的插件/系统/第三方工具对洛谷服务"**进行干扰、破坏、修改或施加其他影响**"	低频只读不构成"干扰破坏"；**实时高频抓取很危险**
§3.4.10	不得**占用、浪费**洛谷服务器资源	**直接否定"运行时实时抓取"**
§4.1	内容**仅可作私人和非商业用途**；不得"发布、播放……或改写或再发行"	**直接否定"把洛谷题库打进对外分发的 exe"**

> ⚠️ **不要说过头**：协议全文**没有出现"爬虫/crawler"字样**。准确表述是"受 §3.4.9/§3.4.10 约束"，而不是"洛谷明文禁止爬虫"。

4.2 社区规则

- 第八条第 6 项：「制作、散布或使用损害洛谷或其他用户利益的**插件、软件、脚本**等」→ **封禁账户**
- 第十条：提交卡评测代码、大量无意义提交 → 封禁

4.3 题解的 AI 禁令 —— 对现有功能是硬约束

洛谷题解规范明确：**「关键思路、论证过程、代码等内容不得使用生成式 AI 辅助产生」**。

> 本项目**已有 AI 助教**。这意味着：AI 解析**只能留在本地给学生看**，**绝不能**做成"一键发到洛谷题解区"。**这个功能不能做。**

4.4 官方唯一授权通道

洛谷开放平台 `docs.lgapi.cn/open` ——"为**教育机构、开发者及在线评测系统（OJ）**提供一站式题库接入与评测服务"。§3.2 已说明现状（限量邀请测试）。

4.5 高级团队（教师侧的现成方案）

项	事实
价格	**699 元/年**（可 10 元试用 30 天），可对公转账、开增值税发票
作业人数上限	普通团队 **20 人**；高级团队 **250 人**
判题	由洛谷评测机自动完成；**可导出做题数据为电子表格**
已知坑	学生**必须手动点「参与作业」**，否则不统计；截止后提交不计入

> **注意**：这是**老师**的方案，不是 app 的方案。app 无法替老师建团队。

五、方案对比

	A. 链接直达	B. 离线精选镜像	C. 官方开放平台	D. 实时抓取
做法	讲义里的洛谷链接变成可点，系统浏览器打开（复用现有 `/open?url=`）	用**官方 NDJSON** 在构建期挑 **100–200 题**（难度1–2）进 `content/luogu/`	走 `open-v1.lgapi.cn`	每次开 app 实时请求
改动量	**≈0**（基础设施已有）	**小–中**（NDJSON 已是结构化，加筛选+本地缓存）	大（等邀请 + 对接 + SDK 自己写）	中
离线	❌ 破坏（跳浏览器）	✅ **保持**	🟡 部分	❌ 破坏
合规	✅ 无风险	🟡 **官方渠道，但 §4.1 管"再分发"**	✅ 唯一授权	❌ 踩 §3.4.10
稳定性	✅	✅ 抓一次即固化	✅	❌ 随时失效
体验	中	**高**	高	高
推荐	✅ **立刻做**	✅ **主力方案**	✅ **主动申请**	❌ **不做**

六、建议

6.1 立刻做（成本 ≈ 0）

1. **把讲义里的洛谷链接变成可点。**项目已有 `/open?url=` 路由和 `openModal` 机制，几乎不用写代码。
2. **在「试一试 / 可视化」成功界面加"去洛谷练同类题"** —— 指向 `luogu.com.cn/problem/list?tag=<id>&difficulty=1`，**只跳转、不抓取。**

6.2 主力方案：离线精选镜像（1–2 天）

3. **构建期**下载官方 NDJSON（26.8 MB），按**知识点 → 标签/难度**挑题：

约束	值
难度	**只取 1–2**（入门 / 普及−）——北师大同款约束，Python 能在限时内过
题量	**100–200 道**（每知识点 3–5 道）
字段	只留 `pid/title/difficulty/tags/description/inputFormat/outputFormat/samples/hint`
时机	**只在构建期跑一次**，不是运行时
频率	一次性 CDN 下载，**不轮询**

4. **硬红线（必须遵守）**：
   - ❌ **不要把洛谷题库打进 `app/dist/`** ——那是要**拷给同学、连 exe 一起发出去**的目录，等于"再发行"，踩 §4.1。
   - ✅ 放在**个人内容目录**（`%LOCALAPPDATA%\course-terminal\content\` 或项目 `content/`），自用。
   - ✅ 保留来源标注（`来源：洛谷 P1001 https://www.luogu.com.cn/problem/P1001`）——课程讲义自己就是这么做的。
   - ❌ AI 生成的解析**不得**对外发布为洛谷题解。

6.3 正道（中期）

5. **给 `k@luogu.org` 发申请邮件**：说明是**高校课程配套的非商业教学工具**，申请开放平台测试资格。拿到了才是可持续的。

6.4 明确不做

6. ❌ **运行时实时抓取**（踩 §3.4.10 + 破坏"离线"承诺 + 脆弱）
7. ❌ **把洛谷题库打包进对外分发的产物**（踩 §4.1）
8. ❌ **AI 解析提交到洛谷题解区**（违反题解规范）

附录：复现方式

一手实测脚本在 `D:\opencode\course-terminal\_dev\`（原始响应存 `_dev/luogu_raw/`）：

脚本	作用
`luogu_probe2.py`	抓完整响应头 + 对照组，分离"代理 / 请求头 / 302 挑战"三个变量
`luogu_probe3.py`	浏览器同款请求头 + CookieJar → **突破，拿到 200**
`luogu_probe5.py`	分层测试 6 个接口，得到 200/401 分界
`luogu_probe6.py`	定位 `lentille-context` 注入点
`luogu_probe7.py`	导出 `data.problem` 18 字段 + 列表页结构
`luogu_probe8.py`	难度/标签分布量化
`luogu_probe9.py`	**验证官方离线库匿名可下（HEAD 200 + 26.8 MB）**
`luogu_probe10.py`	**拉全并解析：17,546 题 / 14 字段 / 难度分布**

全部请求：只读、低频（≥3 秒间隔）、不登录、不提交、不绕风控。 平台与先例事实来自三路独立调研（产物：`D:\opencode\luogu-research-report.md`）。